

AVANCÉES EN THÉORIE PAC-BAYÉSIENNE

DE BORNES EN GÉNÉRALISATION À DES ALGORITHMES D'APPRENTISSAGE SUPERVISÉ ET DE TRANSFERT

Soutenance HDR — 7 avril 2025

Emilie MORVANT

Université Jean Monnet - Laboratoire Hubert Curien

Rapporteurs	Marianne CLAUSEL	Professeure	Université de Lorraine
	Colin DE LA HIGUERA	Professeur	Université de Nantes
	Liva RALAIVOLA	VP Recherche	Criteo AI Lab
Examineurs		Professeur	Aix-Marseille Université
	Stéphane CHRÉTIEN	Professeur	Université Lyon 2
	Rémi EMONET	MCF HDR	Université Jean Monnet
Tuteur	François JACQUENET	Professeur	Université Jean Monnet

Parcours



Parcours



Responsable Licence 2 d'informatique

Responsable
L1 d'info

Monitorat

Décharge jeune chercheur


Entre 250h et 300h par an

(M1 Méthodologie de la Recherche
M1 Analyse de données
M2 Intro à l'IA)

L1-L2 Programmation
L2 Systèmes d'exploitation

co-encadrements de stagiaires


Parcours




Intelligence Artificielle (IA)

méthodes permettant de faire réaliser à une machine
des tâches plus ou moins complexes

Ma trajectoire de recherche




Ma trajectoire de recherche



ENJEUX SOCIÉTAUX EN IA


Ma trajectoire de recherche



ENJEUX SOCIÉTAUX EN IA

- **Confiance**


Ma trajectoire de recherche



ENJEUX SOCIÉTAUX EN IA

- **Confiance**
- **Explicabilité**


Ma trajectoire de recherche



ENJEUX SOCIÉTAUX EN IA

- **Confiance**
- **Explicabilité**
- **Adaptabilité**


Ma trajectoire de recherche



ENJEUX SOCIÉTAUX EN IA

- **Confiance**
- **Explicabilité**
- **Adaptabilité**
- **Robustesse**


Ma trajectoire de recherche




ENJEUX SOCIÉTAUX EN IA

- **Confiance**
- **Explicabilité**
- **Adaptabilité**
- **Robustesse**
- **Équité**


Ma trajectoire de recherche





Thèmes principaux et publications





	Toutes	Depuis 2020
Citations	1213	952
indice h	16	13
indice i10	20	15





Thèmes principaux et projets





Thèmes principaux et projets



Thèmes principaux et projets



Thèmes principaux et projets




CONTEXTE SCIENTIFIQUE GÉNÉRAL

Classification supervisée

Tâche de **classification supervisée**


Classer les animaux en 2 catégories :  avec des ailes ou  sans ailes



Classification supervisée

Tâche de **classification supervisée**


Classer les animaux en 2 catégories :  avec des ailes ou  sans ailes



Classification supervisée

Tâche de **classification supervisée**



Classer les animaux en 2 catégories :  avec des ailes ou  sans ailes




Classification supervisée

Tâche de **classification supervisée**

Classer les animaux en 2 catégories :  avec des ailes ou  sans ailes




Bornes en généralisation




erreur sur
toutes les données $\leq$
NON CALCULABLE

Bornes en généralisation




$$\underbrace{\text{erreur sur toutes les données}}_{\text{NON CALCULABLE}} \leq \underbrace{\text{erreur sur les données observées} + f\left(\text{nombre de données observées}\right)}_{\text{CALCULABLE (ou estimable)}}$$

Bornes en généralisation




$$\underbrace{\text{erreur sur toutes les données}}_{\text{NON CALCULABLE}} \leq \underbrace{+ f \left(\begin{array}{c} \text{complexité} \\ \text{de } h \end{array} \right)}_{\text{CALCULABLE (ou estimable)}}$$

Bornes en généralisation



$$\underbrace{\text{erreur sur toutes les données}}_{\text{NON CALCULABLE}} \leq \underbrace{\text{erreur sur les données observées} + f \left(\begin{array}{cc} \text{complexité de } h & \text{nombre de données observées} \end{array} \right)}_{\text{CALCULABLE (ou estimable)}}$$

Bornes en généralisation



$$\text{erreur sur toutes les données} \leq \text{erreur sur les données observées} + f \left(\begin{matrix} \text{complexité} \\ \text{de } h \end{matrix}, \begin{matrix} \text{nombre de} \\ \text{données observées} \end{matrix} \right)$$

Pour apprendre un modèle avec de **bonnes garanties en généralisation**, on peut minimiser le compromis entre **erreur sur les données observées** et **complexité du modèle**

Formalisation pour la classification supervisée

$\mathbb{X} \in \mathbb{R}^d$ espace d'entrée

$\mathbb{Y} = \{-1, +1\}$ espace de sortie

$\mathbb{H}$ ensemble de modèles tel que $\forall h \in \mathbb{H}, h : \mathbb{X} \rightarrow \mathbb{Y}$

$\mathcal{D}$ distribution sur $\mathbb{X} \times \mathbb{Y}$

$\mathbb{S} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m \stackrel{iid}{\sim} (\mathcal{D})^m$ ensemble d'apprentissage

Risque empirique associé : $\hat{R}_{\mathbb{S}}(h) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}[h(\mathbf{x}) \neq y]$

Classification supervisée

Objectif : Trouver le modèle h de $\mathbb{H}$ qui minimise l'erreur sur toutes les données $R_{\mathcal{D}}(h)$

$$R_{\mathcal{D}}(h) = \underbrace{\mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \mathbb{I}[h(\mathbf{x}) \neq y]}_{\text{Risque réel}}$$

Formes des bornes en généralisation PAC (Valiant, 1984)

Borne en généralisation dites **Probably Approximately Correct**

Étant donné une distribution $\mathcal{D}$ sur $\mathbb{X} \times \mathbb{Y}$, pour tout $\delta \in (0, 1]$, on a

$$\mathbb{P}_{\mathcal{S} \sim \mathcal{D}^m} \left[\underbrace{R_{\mathcal{D}}(h)}_{\text{Risque réel}} \leq \underbrace{\hat{R}_{\mathcal{S}}(h)}_{\text{Risque empirique}} + \underbrace{\Phi(h, \mathcal{S}, \delta)}_{\text{Complexité}} \right] \geq 1 - \delta$$

Avec une grande probabilité d'au moins $1 - \delta$, le risque de h est plus petit que $\hat{R}_{\mathcal{S}}(h) + \Phi(h, \mathcal{S}, \delta)$

On veut que les bornes soient

- **Informatives** $\iff \hat{R}_{\mathcal{S}}(h) + \Phi(h, \mathcal{S}, \delta) \leq 1$
- **Précises** $\iff |R_{\mathcal{D}}(h) - \hat{R}_{\mathcal{S}}(h)| \simeq \Phi(h, \mathcal{S}, \delta)$
- **Fiables** $\iff$ un petit δ augmente la fiabilité de la borne, mais diminue sa précision
- **Calculables (facilement)** $\iff \hat{R}_{\mathcal{S}}(h) + \Phi(h, \mathcal{S}, \delta)$ est calculable/majorable avec $\mathcal{S}$

Formes des bornes en généralisation PAC (Valiant, 1984)

Borne en généralisation dites **Probably Approximately Correct**

Étant donné une distribution $\mathcal{D}$ sur $\mathbb{X} \times \mathbb{Y}$, pour tout $\delta \in (0, 1]$, on a

$$\mathbb{P}_{\mathcal{S} \sim \mathcal{D}^m} \left[\underbrace{R_{\mathcal{D}}(h)}_{\text{Risque réel}} \leq \underbrace{\hat{R}_{\mathcal{S}}(h)}_{\text{Risque empirique}} + \underbrace{\Phi(h, \mathcal{S}, \delta)}_{\text{Complexité}} \right] \geq 1 - \delta$$

Avec une grande probabilité d'au moins $1 - \delta$, le risque de h est plus petit que $\hat{R}_{\mathcal{S}}(h) + \Phi(h, \mathcal{S}, \delta)$

Trois grandes familles de bornes en généralisation PAC :

- Bornes en convergence uniforme (VAPNIK et al., 1971 ; BARTLETT et al., 2002)
- Bornes dépendantes d'un algorithme (BOUSQUET et al., 2002 ; XU et al., 2012)
- Bornes PAC-Bayésiennes (SHAWE-TAYLOR et al., 1997 ; MCALLESTER, 1998)

Les trois familles de bornes

Borne en convergence uniforme pour un ensemble de modèles $\mathbb{H}$

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[\forall h \in \mathbb{H}, R_{\mathcal{D}}(h) \leq \hat{R}_{\mathbb{S}}(h) + \Phi(\mathbb{H}, \mathbb{S}, \delta) \right] \geq 1 - \delta$$

Borne en pire cas

Fixe pour tout $h \in \mathbb{H}$

- Valable pour tous les modèles de $\mathbb{H}$

↪ Bornes en pire cas $\rightsquigarrow$ souvent trop pessimistes

- $\Phi(h, \mathbb{S}, \delta)$ fixe pour tous les modèles de $\mathbb{H}$, par exemple

- ▶ Dimension de Vapnik-Chervonenkis (VC-dim) de $\mathbb{H}$

✓ Peut être simple à interpréter (capacité d'apprentissage de $\mathbb{H}$)

✗ Peut être très grande voir infinie $\rightsquigarrow$ Borne non informative

- ▶ Complexité Rademacher de $\mathbb{H}$

✓ Plus précise que la VC-dim (prise en compte de $\mathcal{D}$)

✗ Peut être difficile à calculer en pratique

Les trois familles de bornes

Borne dépendante d'un algorithme $\mathcal{A} : \mathbb{S} \mapsto h_{\mathbb{S}}$

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[\mathbf{R}_{\mathcal{D}}(h_{\mathbb{S}}) \leq \hat{\mathbf{R}}_{\mathbb{S}}(h_{\mathbb{S}}) + \Phi(\mathcal{A}, \mathbb{S}, \delta) \right] \geq 1 - \delta$$

Valide uniquement pour
 $h_{\mathbb{S}}$ appris avec $\mathcal{A}$ et $\mathbb{S}$

dépend de caractéristiques
de l'algorithme $\mathcal{A}$

- Valable pour un seul modèle $h_{\mathbb{S}} \rightarrow$ celui appris $\mathcal{A}$
 - $\hookrightarrow$ Plus réaliste mais moins générale
- $\Phi(\mathcal{A}, \mathbb{S}, \delta)$ dépend de propriétés de $\mathcal{A}$, par exemple
 - ▶ Stabilité algorithmique
 - ✓ Capture la résistance à de faibles variations dans les données
 - ✗ Peut-être difficile à estimer
 - ▶ Robustesse algorithmique
 - ✓ Capture la résistance aux variations dans une même zone de l'espace
 - ✗ Peut être difficile à calculer en pratique

Les trois familles de bornes

Borne PAC-Bayésiennes

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[\forall \rho, \mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h) \leq \mathbb{E}_{h \sim \rho} \hat{R}_{\mathbb{S}}(h) + \Phi(\Delta(\rho, \pi), \mathbb{S}, \delta) \right] \geq 1 - \delta$$

Borne en espérance sur $\mathbb{H}$

Dépend d'une distance Δ
entre ρ et un apriori π

- Borne en espérance sur $\mathbb{H}$
 - ↪ souvent plus précises que les bornes en pire cas
 - ↪ borne sur un risque stochastique sur $\mathbb{H}$
- Mais l'espérance sur $\mathbb{H}$ est étroitement liée au vote de majorité sur $\mathbb{H}$
- Peut être facilement calculable (ou majorable)
 - ↪ et minimisable $\Rightarrow$ algorithme auto-certifié
- $\Phi(\Delta(\rho, \pi), \mathbb{S}, \delta)$ dépend
 - ▶ du choix d'un *a priori* π sur l'espérance
 - ▶ d'une distance $\Delta(\rho, \pi)$ entre ρ et π (ex. KL-divergence)

Les trois familles de bornes

Borne en convergence uniforme pour un ensemble de modèles $\mathbb{H}$

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[\forall h \in \mathbb{H}, R_{\mathcal{D}}(h) \leq \hat{R}_{\mathbb{S}}(h) + \Phi(\mathbb{H}, \mathbb{S}, \delta) \right] \geq 1 - \delta$$

Borne en pire cas

Fixe pour tout $h \in \mathbb{H}$

Borne dépendante d'un algorithme $\mathcal{A} : \mathbb{S} \mapsto h_{\mathbb{S}}$

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[R_{\mathcal{D}}(h_{\mathbb{S}}) \leq \hat{R}_{\mathbb{S}}(h_{\mathbb{S}}) + \Phi(\mathcal{A}, \mathbb{S}, \delta) \right] \geq 1 - \delta$$

Valide uniquement pour
 $h_{\mathbb{S}}$ appris avec $\mathcal{A}$ et $\mathbb{S}$

dépend de caractéristiques
de l'algorithme $\mathcal{A}$

Borne PAC-Bayésienne

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[\forall \rho, \mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h) \leq \mathbb{E}_{h \sim \rho} \hat{R}_{\mathbb{S}}(h) + \Phi(\Delta(\rho, \pi), \mathbb{S}, \delta) \right] \geq 1 - \delta$$


Borne en espérance sur $\mathbb{H}$

Dépend d'une distance Δ
entre ρ et un apriori π

LA THÉORIE PAC-BAYÉSIENNE

Un peu plus en détails

La théorie PAC-Bayésienne — Le vote de majorité



$\mathbb{H}$: Ensemble de modèles simples (*i.e.*, de **votants**), ici 3 votants $\{h_1, h_2, h_3\}$

$\Rightarrow$ Apprendre une combinaison **pondérée** des votants $\iff$ Un vote de majorité **MV**

$$MV(\cdot) = \text{sign} \left[\sum_{h \in \mathbb{H}} \overbrace{\rho(h)}^{\text{poids de } h} h(\cdot) \right]$$

Classification supervisée PAC-Bayésienne

$\mathbb{X} \in \mathbb{R}^d$ espace d'entrée

$\mathbb{Y} = \{-1, +1\}$ espace de sortie


$\mathbb{H}$ ensemble de votants tel que $\forall h \in \mathbb{H}, h : \mathbb{X} \rightarrow \mathbb{Y}$

$\mathcal{D}$ distribution sur $\mathbb{X} \times \mathbb{Y}$

$\mathbb{S} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m \stackrel{iid}{\sim} \mathcal{D}^m$ ensemble d'apprentissage

π **distribution prior** sur $\mathbb{H}$

ρ **distribution posterior** sur $\mathbb{H}$



Classification supervisée PAC-Bayésienne

Objectif : Trouver le vote de majorité pondéré MV sur $\mathbb{H}$ qui minimise $R_{\mathcal{D}}(MV)$

$$\underbrace{R_{\mathcal{D}}(MV) = \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}} \mathbb{I}[MV(\mathbf{x}) \neq y]}_{\text{Risque réel}} \quad \text{où} \quad MV(\mathbf{x}) = \text{sign} \left[\mathbb{E}_{h \sim \rho} h(\mathbf{x}) \right]$$

Un point clé en PAC-Bayes : Le risque de Gibbs

Risque de Gibbs = espérance des risques individuels

$$R_{\mathcal{D}}(\text{MV}) \leq 2 \times \mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h)$$

Avantages :

- Les garanties en **garanties en espérances** sur l'ensemble des votants $\mathbb{H}$
 $\implies$ permettent d'avoir des garanties sur un modèle déterministe
- Permet de faire intervenir la **diversité** des votants

Important :

- D'autres bornes supérieures de $R_{\mathcal{D}}(\text{MV})$ existent

Les ingrédients d'une borne PAC-Bayésienne

Rappel : Forme d'une borne en généralisation PAC

$$\text{risque réel} \leq \text{risque empirique} + f \left(\text{complexité}(h), \frac{1}{m} \right)$$

- Risque de Gibbs réel sur la distribution $\mathcal{D}$: $\mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h)$
- Risque empirique sur m exemples $\mathcal{S} = \{(\mathbf{x}_i, y_i)\}_{i=1}^m \sim (\mathcal{D})^m$:

$$\mathbb{E}_{h \sim \rho} \hat{R}_{\mathcal{S}}(h) = \frac{1}{m} \sum_{i=1}^m \mathbb{E}_{h \sim \rho} \mathbb{I}[h(\mathbf{x}_i) \neq y_i] \quad (\text{risque de Gibbs empirique})$$

- Complexité (divergence de Kullback-Leiber) : $\text{KL}(\rho \parallel \pi) = \mathbb{E}_{h \sim \rho} \ln \frac{\rho(h)}{\pi(h)}$
- Une mesure de déviation convexe entre les risques réel et empirique $D : [0, 1] \times [0, 1] \rightarrow \mathbb{R}$

Borne PAC-Bayésienne générale

avec $D(a, b) = (a - b)^2$ (borne de la forme de McAllester)

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[\underbrace{\mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h)}_{\text{risque réel}} \leq \underbrace{\mathbb{E}_{h \sim \rho} \hat{R}_S(h)}_{\text{risque empirique}} + \sqrt{\frac{1}{2m} \left(\underbrace{\text{KL}(\rho \parallel \pi)}_{\text{complexité}} + \ln \frac{2\sqrt{m}}{\delta} \right)} \right] \geq 1 - \delta$$

Borne PAC-Bayésienne générale

avec $D(a, b) = (a - b)^2$ (borne de la forme de McAllester)

$$\mathbb{P}_{\mathcal{S} \sim \mathcal{D}^m} \left[\underbrace{\mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h)}_{\text{risque réel}} \leq \underbrace{\mathbb{E}_{h \sim \rho} \hat{R}_{\mathcal{S}}(h)}_{\text{risque empirique}} + \sqrt{\frac{1}{2m} \left(\underbrace{\text{KL}(\rho \parallel \pi)}_{\text{complexité}} + \ln \frac{2\sqrt{m}}{\delta} \right)} \right] \geq 1 - \delta$$

Théorème PAC-Bayésien général

Pour toute distribution $\mathcal{D}$ on $\mathbb{X} \times \mathbb{Y}$, pour tout ensemble de votants $\mathbb{H}$, pour toute distribution prior π sur $\mathbb{H}$, pour tout $\delta \in (0, 1]$, pour toute fonction convexe $D : [0, 1] \times [0, 1] \rightarrow \mathbb{R}$, on a

$$\mathbb{P}_{\mathcal{S} \sim \mathcal{D}^m} \left[\underbrace{\mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h)}_{\text{risque réel}} \leq \underbrace{\mathbb{E}_{h \sim \rho} \hat{R}_{\mathcal{S}}(h)}_{\text{risque empirique}} + \sqrt{\frac{1}{2m} \left(\underbrace{\text{KL}(\rho \parallel \pi)}_{\text{complexité}} + \ln \frac{2\sqrt{m}}{\delta} \right)} \right] \geq 1 - \delta$$

SUR LA FLEXIBILITÉ DU PAC-BAYES

Principe simplifié de mes contributions

- Dérivation de **nouvelles bornes** en généralisation PAC-Bayésiennes pour différents cadres
- Dérivation d'algorithmes d'**apprentissage supervisé**
 - ▶ Soit en s'inspirant des bornes
 - ▶ Soit en minimisant directement les bornes $\rightsquigarrow$ **Algorithmes auto-certifiés**


Fil rouge : une borne PAC-Bayésienne

Pour toute distribution $\mathcal{D}$ sur $\mathbb{X} \times \mathbb{Y}$, pour tout ensemble de votants $\mathbb{H}$,
pour toute **distribution prior** π sur $\mathbb{H}$, pour tout $\delta \in (0, 1]$, on a

$$\mathbb{P}_{\mathcal{S} \sim \mathcal{D}^m} \left[\forall \text{ distribution posterior } \rho \text{ sur } h, \right. \\ \left. \underbrace{\mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h)}_{\text{risque réel}} \leq \underbrace{\mathbb{E}_{h \sim \rho} \hat{R}_{\mathcal{S}}(h)}_{\text{risque empirique}} + \sqrt{\frac{1}{2m} \left(\underbrace{\text{KL}(\rho \| \pi)}_{\text{complexité}} + \ln \frac{2\sqrt{m}}{\delta} \right)} \right] \geq 1 - \delta$$

Adaptation de domaine d'une tâche source vers une tâche cible

L'être humain est capable de s'adapter à une nouvelle tâche à partir de connaissances acquises



En apprentissage automatique

Se traduit par le besoin d'une mesure de capacité d'adaptation entre les tâches

Adaptation de domaine d'une tâche source vers une tâche cible


Deux distributions de données sur $\mathbb{X} \times \mathbb{Y}$

$\mathcal{S}$ domaine source $\mathcal{T}$ domaine cible

Deux échantillons d'observations

$\mathbf{S} \sim \mathcal{S}$ étiqueté $\mathbf{T} \sim \mathcal{T}_{\mathbb{X}}$ non étiqueté

$\text{dist}(\mathcal{S}, \mathcal{T})$: Distance entre domaines



La distance entre les domaines permet de relier les deux domaines


$\iff$ À quel point peut-on utiliser les étiquettes sources pour minimiser le risque cible ?

$$\mathbb{P}_{\substack{\mathbf{S} \sim \mathcal{S} \\ \mathbf{T} \sim \mathcal{T}_{\mathbb{X}}}} \left[\begin{array}{l} \forall \text{ posterior } \rho \text{ sur } \mathbb{H}, \\ \mathbb{E}_{h \sim \rho} R_{\mathcal{T}}(h) \leq \underbrace{\mathbb{E}_{h, h' \sim \rho} \hat{R}_{\mathcal{T}}(h, h')}_{\text{désaccord (sans étiquette)}} + \frac{1}{\text{dist}(\mathcal{S}, \mathcal{T})} \times \underbrace{\mathbb{E}_{h, h' \sim \rho} \hat{R}_{\mathcal{S}}(h, h')}_{\text{erreur jointe (avec étiquettes)}} + \Phi(\text{KL}(\rho \| \pi), (\mathcal{S} \cup \mathcal{T}), \delta) \end{array} \right] \geq 1 - \delta$$

$$= \sum_{\mathbf{x} \in \mathbb{T}} \frac{1}{|\mathbb{T}|} \mathbb{I}[h(\mathbf{x}) \neq h'(\mathbf{x})] \qquad = \sum_{(\mathbf{x}, y) \in \mathcal{S}} \frac{1}{|\mathcal{S}|} \mathbb{I}[h(\mathbf{x}) \neq y] \mathbb{I}[h'(\mathbf{x}) \neq y]$$

PAC-Bayes pour la robustesse adverse

Comment garantir que le modèle sera résistant à des attaques malveillantes imperceptibles ?



On veut garantir que le modèle **se trompe le moins possible sur des données bruitées**

PAC-Bayes pour la robustesse adverse


Espace des **données** $\times$ Espace des **bruits**

$$\underbrace{(\mathbb{X} \times \mathbb{Y})}_{\mathcal{E} \text{ distribution sur } (\mathbb{X} \times \mathbb{Y}) \times \mathbb{B}} \times \mathbb{B}$$

Ensemble d'apprentissage **perturbé/bruité**

$$\hat{\mathbb{S}} = \left\{ \left((\mathbf{x}_i, y_i), \{\epsilon_j^i\}_{j=1}^n \right) \right\}_{i=1}^m \sim (\mathcal{E}^n)^m$$



$\Leftrightarrow$ Chaque **exemple** $(\mathbf{x}_i, y_i)$ est perturbé avec **n bruits**



$$\mathbb{P}_{\hat{\mathbb{S}} \sim (\mathcal{E}^n)^m} \left[\forall \text{ posterior } \rho \text{ sur } \mathbb{H}, \quad \mathbb{E}_{h \sim \rho} R_{\mathcal{E}}(h) \leq \mathbb{E}_{h \sim \rho} \hat{R}_{\hat{\mathbb{S}}}(h) + \sqrt{\frac{1}{m} \left[\text{KL}(\rho \| \pi) + \ln \frac{m+1}{\delta} \right]} \right] \geq 1 - \delta$$

$$\text{où } R_{\mathcal{E}}(h) = \mathbb{E}_{((\mathbf{x}, y), \epsilon) \sim \mathcal{E}} \mathbb{I}[h(\mathbf{x} + \epsilon) \neq y] \quad \text{et} \quad \hat{R}_{\hat{\mathbb{S}}}(h) = \frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n \mathbb{I}[h(\mathbf{x}_i + \epsilon_j^i) \neq y_i]$$

Fusion/Combinaison des vues




Apprentissage multi-vues PAC-Bayésien

$\mathbf{V}$ ensemble de V vues

$\mathbb{X} = \mathbb{X}^1 \times \dots \times \mathbb{X}^V$ espace d'entrée multi-vues

$\forall v \in \mathbf{V}, \mathbb{H}^v$ un ensemble de votants par vue

$\forall h \in \mathbb{H}^v, h : \mathbb{X}^v \rightarrow \mathbb{R}$



Hiéarchie de distributions sur les votants

π distribution **hyper-prior** sur $\mathbf{V}$

$\forall v \in \mathbf{V}, P^v$ distribution **prior** sur $\mathbb{H}^v$

ρ distribution **hyper-posterior** sur $\mathbf{V}$

$\forall v \in \mathbf{V}, Q^v$ distribution **posterior** sur $\mathbb{H}^v$

$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[\forall v \in \mathbf{V}, \forall \text{posterior } Q^v \text{ sur } \mathbb{H}^v, \forall \text{hyper-posterior } \rho \text{ sur } \mathbf{V}, \right. \\ \left. \mathbb{E}_{v \sim \rho} \mathbb{E}_{h \sim Q^v} R_{\mathcal{D}}(h) \leq \mathbb{E}_{v \sim \rho} \mathbb{E}_{h \sim Q^v} \hat{R}_S(h) + \sqrt{\frac{1}{2m} \left(\mathbb{E}_{v \sim \rho} \text{KL}(Q^v \| P^v) + \text{KL}(\rho \| \pi) + \ln \frac{2\sqrt{m}}{\delta} \right)} \right] \geq 1 - \delta$$

Le vote de majorité stochastique PAC-Bayésien


Rappel

$\mathbb{E}_{h \sim \rho} R(h) \rightsquigarrow$ Les bornes PAC-Bayésiennes sont probabilistes sur $\mathbb{H}$

$\rightsquigarrow$ Elles portent sur un modèle stochastique, plutôt qu'un modèle déterministe

MAIS elles permettent de borner le risque du vote de majorité $MV(\cdot) = \text{sign} \left[\mathbb{E}_{h \sim \rho} h(\cdot) \right]$

$\rightarrow$ Via des relaxations *plus ou moins* précises et pas nécessairement facile à minimiser




Le vote de majorité stochastique PAC-Bayésien

Une sorte de hiérarchie de distributions sur les votants

Π hyper-prior sur $\mathbb{H}$ (distribution de dirichlet)

P hyper-posterior $\mathbb{H}$ ρ posterior tirée selon P
 $\hookrightarrow MV(\cdot) = \text{sign} \left[\mathbb{E}_{h \sim \rho} h(\cdot) \right]$



$$\mathbb{P}_{S \sim \mathcal{D}^m} \left[\forall \text{ hyper-posterior } P \text{ sur } \mathbb{H}, \mathbb{E}_{\rho \sim P} R_{\mathcal{D}}(MV) \leq \mathbb{E}_{\rho \sim P} \hat{R}_S(MV) + \sqrt{\frac{1}{2m} \left(\text{KL}(P \parallel \Pi) + \ln \frac{2\sqrt{m}}{\delta} \right)} \right] \geq 1 - \delta$$

Désintégration des bornes PAC-Bayésiennes


Rappel

$\mathbb{E}_{h \sim \rho} R(h) \rightsquigarrow$ Les bornes PAC-Bayésiennes sont probabilistes sur $\mathbb{H}$

$\rightsquigarrow$ Elles portent sur un modèle stochastique, plutôt qu'un modèle déterministe



Désintégrer les bornes permet de ne les faire porter que sur un **seul** modèle




Désintégration des bornes PAC-Bayésiennes

$\mathbb{S} \sim \mathcal{D}^m$ ensemble d'apprentissage

π distribution prior sur $\mathbb{H}$

A algorithme déterministe

$\hookrightarrow A(\mathbb{S}, \pi) = \rho_{\mathbb{S}}$ distribution posterior sur $\mathbb{H}$



$$\mathbb{P}_{\substack{\mathbb{S} \sim \mathcal{D}^m \\ h \sim \rho_{\mathbb{S}}}} \left[R_{\mathcal{D}}(h) \leq \hat{R}_{\mathbb{S}}(h) + \sqrt{\frac{1}{2m} \left[\underbrace{D_{\alpha}(\rho_{\mathbb{S}} \| \pi)}_{\text{Divergence de Rényi :}} + \frac{2\alpha - 1}{\alpha - 1} \ln \frac{1}{\alpha} + \ln(2\sqrt{m}) \right]} \right] \geq 1 - \delta$$

$$D_{\alpha}(\rho_{\mathbb{S}} \| \pi) = \frac{1}{\alpha - 1} \ln \left[\mathbb{E}_{h \sim \pi} \left[\frac{\rho_{\mathbb{S}}(h)}{\pi(h)} \right]^{\alpha} \right]$$


Complexités arbitraires

Une remarque importante

Le terme de complexité dans les bornes en généralisation dépend du cadre considéré



Comment rendre les bornes plus flexibles ?




Complexités arbitraires

On considère une **fonction personnalisable** $\mu : \mathbb{H} \times (\mathbb{X} \times \mathbb{Y})^m \rightarrow \mathbb{R}$ (e.g., une régularisation)

$\mathbb{S} \sim \mathcal{D}^m$ ensemble d'apprentissage

π distribution **prior** sur $\mathbb{H}$

$\rho_{\mathbb{S}}$ distribution **posterior** sur $\mathbb{H}$
telle que $\rho_{\mathbb{S}}(h) \propto e^{\mu(h, \mathbb{S})}$



Forme générale : $\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m, h \sim \rho_{\mathbb{S}}} \left[R_{\mathcal{D}}(h) \leq \hat{R}_{\mathbb{S}}(h) + \Phi_{\mu}(h, \mathbb{S}, \delta) \right] \geq 1 - \delta$

$$\mathbb{P}_{\substack{h' \sim \pi, \\ \mathbb{S} \sim \mathcal{D}^m, h \sim \rho_{\mathbb{S}}}} \left[R_{\mathcal{D}}(h) \leq \hat{R}_{\mathbb{S}}(h) + \sqrt{\frac{1}{2m} \left[\underbrace{\mu(h', \mathbb{S})}_{\text{Prior}} - \underbrace{\mu(h, \mathbb{S})}_{\text{Posterior}} + \frac{8\sqrt{m}}{\delta^2} \right]_+} \right] \geq 1 - \delta$$

Propriétés clés des bornes PAC-Bayésiennes

- **Flexibles** et adaptables à différents scénarios
 - ▶ Compatibles avec différents types de modèles
 - ▶ Modèle stochastique par nature
 - ▶ Modèle déterministe par nature via les votes de majorité
 - ▶ Modèle déterministe via la désintégration
 - ▶ (Hiérarchie de) distributions sur des ensembles (de modèles ou d'autres objets)
- **Intermédiaires** entre bornes en convergence uniforme et dépendante d'un algorithme
 - ▶ Les complexités arbitraires permettent même de retrouver ces deux types de bornes
- **Précises** et informatives
 - ▶ Particulièrement pour affiner un modèle *a priori*
- **Pratiques** et exploitables $\rightsquigarrow$ Souvent calculables ou majorables
 - ▶ Minimisables directement via un algorithme auto-certifié
 - ▶ Meilleure explicabilité et confiance des modèles par nature de l'algorithme

Forme générale des résultats

Forme générale des bornes PAC-Bayésiennes

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[\forall \rho, D \left(\mathbb{E}_{h \sim \rho} R_{\mathcal{D}}(h), \mathbb{E}_{h \sim \rho} \hat{R}_{\mathbb{S}}(h) \right) \leq \Phi(\Delta(\rho, \pi), \mathbb{S}, \delta) \right] \geq 1 - \delta$$

Borne en espérance sur $\mathbb{H}$

$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m, h \sim \rho_{\mathbb{S}}} \left[D(R_{\mathcal{D}}(h), \hat{R}_{\mathbb{S}}(h)) \leq \Phi(\Delta(\rho_{\mathbb{S}}, \pi), \mathbb{S}, \delta) \right] \geq 1 - \delta$$


Borne pour un unique $h \sim \rho_{\mathbb{S}}$ OU Peut être personnalisable



$$\mathbb{P}_{\mathbb{S} \sim \mathcal{D}^m} \left[\underbrace{D(R_{\mathcal{D}}(\text{modèle}), \hat{R}_{\mathbb{S}}(\text{modèle}))}_{\text{écart en généralisation}} \leq \text{Borne} \right] \geq 1 - \delta$$

distance entre risque réel et empirique

ÉCART EN GÉNÉRALISATION



AU-DELÀ DE L'ÉCART EN GÉNÉRALISATION

Projet de recherche : Au-delà de l'écart en généralisation

Tâche de classification supervisée équitable

Classer des CVs en 2 catégories :


✓ pertinent ✗ non pertinent

Objectif : Trouver un modèle équitable et garantir de bonnes performances

⇒ Ne pas apprendre les biais !

MOINS ÉQUITABLE
erreurs uniquement
sur ♀

PLUS ÉQUITABLE
erreurs sur ♀ & ♂



Projet de recherche : Au-delà de l'écart en généralisation


Tâche de classification supervisée équitable

Classer des CVs en 2 catégories :

✓ pertinent ✗ non pertinent

Objectif : Trouver un modèle équitable et garantir de bonnes performances

⇒ Ne pas apprendre les biais !



Une solution : Considérer une contrainte/mesure d'équité


↪ **Équité** = capacité à bien classer malgré les biais dans les données

- Algorithme auto-certié PAC-Bayésien pour garantir un compromis performance/équité
 - ▶ Contrôle de l'écart entre les **biais observés** et l'**équité espérée**
- Construire des mesures d'équité robustes aux biais


Projet de recherche : Au-delà de l'écart en généralisation

Les bandits manchots


Bras 1 – $r_t(1) \sim \mathcal{D}_1$




Bras 2 – $r_t(2) \sim \mathcal{D}_2$



Bras 3 – $r_t(3) \sim \mathcal{D}_3$



Bras 4 – $r_t(4) \sim \mathcal{D}_4$




Quel bras/machine choisir à l'étape t pour maximiser le gain cumulé (*reward*)

Objectif : Trouver la meilleure stratégie (*policy*) pour maximiser le gain cumulé


Projet de recherche : Au-delà de l'écart en généralisation

Les bandits manchots


Bras 1 – $r_t(1) \sim \mathcal{D}_1$




Bras 2 – $r_t(2) \sim \mathcal{D}_2$



Bras 3 – $r_t(3) \sim \mathcal{D}_3$



Bras 4 – $r_t(4) \sim \mathcal{D}_4$



Quel bras/machine choisir à l'étape t pour maximiser le gain cumulé (*reward*)

Objectif : Trouver la meilleure stratégie (*policy*) pour maximiser le gain cumulé


Une solution : Minimiser le regret au cours du temps

↪ **Regret** = Écart entre **gain cumulé actuel** et **gain optimal** (si le meilleur bras était tjrs choisi)

- Algorithme auto-certifié PAC-Bayésien pour garantir un regret faible
- Analyse dynamique du regret au cours du temps
 - ▶ Étudier comment le PAC-Bayes peut équilibrer exploration et exploitation

Projet de recherche : Au-delà de l'écart en généralisation


la prédiction conforme : quantification de l'incertitude



Objectif : Comment s'assurer qu'un modèle prédit des intervalles fiables, pas trop grands ?

Projet de recherche : Au-delà de l'écart en généralisation

la prédiction conforme : quantification de l'incertitude



Objectif : Comment s'assurer qu'un modèle prédit des intervalles fiables, pas trop grands ?


Une solution : Contrôler un compromis entre couverture et efficacité

↪ **couverture** = l'intervalle doit contenir la vraie valeur dans $X\%$ des cas


↪ **efficacité** = l'intervalle doit être le plus petit possible

- Algorithme auto-certié pour garantir un compromis couverture/efficacité
- Ajustement de la largeur des intervalles via le PAC-Bayes

Projet de recherche : Au-delà de l'écart en généralisation



MERCI POUR VOTRE ATTENTION



Références I

-  Vladimir VAPNIK et Alexey CHERVONENKIS. On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities. *Theory of Probability and its Applications*. (1971).
-  Leslie VALIANT. A Theory of the Learnable. *Communications of the ACM*. (1984).
-  John SHAWE-TAYLOR et Robert WILLIAMSON. A PAC Analysis of a Bayesian Estimator. *Annual Conference on Learning Theory*. (1997).
-  David MCALLESTER. Some PAC-Bayesian Theorems. *Annual Conference on Learning Theory*. (1998).
-  Peter BARTLETT et Shahar MENDELSON. Rademacher and Gaussian Complexities : Risk Bounds and Structural Results. *Journal of Machine Learning Research*. (2002).
-  Olivier BOUSQUET et André ELISSEEFF. Stability and Generalization. *Journal of Machine Learning Research*. (2002).
-  Huan XU et Shie MANNOR. Robustness and Generalization. *Machine Learning*. (2012).